

PREDIKSI PENYAKIT GINJAL KRONIS MENGGUNAKAN MACHINE LEARNING BERDASARKAN INDIKATOR KESEHATAN

SDG 3 : KEHIDUPAN SEHAT & SEJAHTERA

**KELOMPOK 4 DIVISI AI
KHOFIFAH DWI SANNI EL RANDI**



LATAR BELAKANG

Penyakit ginjal kronis berkaitan dengan berbagai kondisi dan indikator kesehatan yang dapat diamati melalui pemeriksaan pasien. Beberapa di antaranya seperti tekanan darah, kadar glukosa, urea, kreatinin, hemoglobin, hipertensi, dan diabetes.

Dalam data kesehatan, terdapat banyak indikator yang dapat digunakan secara bersamaan. Hubungan antara indikator-indikator tersebut dengan kondisi **CKD(Chronic Kidney Disease)** tidak selalu mudah dilihat hanya dengan melakukan pengamatan sederhana.

Karena itu, diperlukan pendekatan berbasis data yang dapat membantu mempelajari pola dari berbagai indikator kesehatan dan menggunakannya untuk melakukan prediksi.



MASALAH YANG INGIN DISELESAIKAN?

- **Deteksi CKD perlu dilakukan lebih awal**

Data kesehatan dapat dimanfaatkan untuk mengenali pola yang berkaitan dengan penyakit ginjal kronis.

- **Banyak indikator kesehatan perlu dianalisis bersama**

Indikator seperti tekanan darah, glukosa, urea, kreatinin, dan hemoglobin saling berkaitan sehingga perlu dianalisis secara menyeluruh.

- **Dibutuhkan pendekatan berbasis data**

Machine Learning dapat memanfaatkan berbagai indikator kesehatan untuk membantu mengklasifikasikan CKD atau Not CKD.

PIHAK YANG BERDAMPAK

- **Pasien / Masyarakat**

Mebutuhkan informasi yang dapat membantu meningkatkan kewaspadaan terhadap kondisi kesehatan

- **Tenaga Kesehatan**

Mebutuhkan informasi dari berbagai indikator kesehatan sebagai bahan pendukung dalam evaluasi pasien

- **Data scientist / Peneliti**

Mebutuhkan metode berbasis data untuk menemukan pola dan menghasilkan prediksi

PEMETAAN MASALAH PREDIKSI CKD

Masalah yang dihadapi?

CKD melibatkan berbagai indikator kesehatan sehingga hubungan antarindikator tidak selalu mudah dikenali. Hal ini membuat klasifikasi CKD dan Non-CKD menjadi lebih sulit

Proses Saat Ini?

Data pemeriksaan perlu dilihat dan dibandingkan berdasarkan berbagai indikator kesehatan. Proses analisis yang dilakukan secara manual membutuhkan waktu dan cukup sulit untuk melihat pola antarindikator.



DAMPAK JIKA MASALAH TIDAK DISELESAIKAN

Pemanfaatan data belum optimal

Berbagai indikator kesehatan yang tersedia belum dimanfaatkan secara maksimal untuk menemukan pola CKD dan Not CKD

Potensi prediksi data masih terabaikan

Data yang telah memiliki kategori CKD dan Not CKD belum dimanfaatkan secara optimal untuk membantu proses klasifikasi

Pola antarindikator dapat terlewat

Hubungan antara beberapa indikator mungkin sulit dikenali melalui pengamatan sederhana

Analisis menjadi kurang praktis

Semakin banyak indikator yang perlu dibandingkan, semakin sulit jika dilakukan satu per satu

Indikator Kesehatan :

- Age — usia
- Blood Pressure — tekanan darah
- BMI — indeks massa tubuh
- Serum Creatinine — kadar kreatinin
- Blood Urea Nitrogen — kadar urea darah
- Serum Albumin — kadar albumin
- Phosphorus & Calcium — kadar mineral dalam darah
- Uric Acid — kadar asam urat
- Urine Albumin & Creatinine — indikator kondisi ginjal
- Albumin-Creatinine Ratio — rasio albumin dan kreatinin urine
- eGFR — estimasi fungsi ginjal
- Diabetes — status diabetes
- Dan indikator kesehatan lainnya

DATASET YANG DIGUNAKAN

CKD-NHANES 2021-2023: Staged Kidney Disease

Karakteristik dataset:

- 11.934 data
- 29 fitur
- 1 target
- Task: **Classification**
- Target: CKD dan Non-CKD
- Periode: NHANES 2021–2023
- Terdiri dari variabel numerik dan kategorikal
- Memiliki missing value

PENDEKATAN MACHINE LEARNING YANG DIGUNAKAN



Project ini menggunakan pendekatan **Supervised Learning** dengan metode **Classification**. Pendekatan ini dipilih karena dataset memiliki label kondisi pasien dan berbagai indikator kesehatan yang dapat digunakan sebagai input

Mengapa Menggunakan Classification?

1. Tipe Problem

CKD atau Not CKD

2. Data Berlabel

25 indikator + target CKD/Not CKD


3. Multiple Indicators

Beberapa indikator perlu dianalisis bersama

4. Output Berupa Kelas

Hasil prediksi: CKD atau Not CKD

DIAGRAM ALUR PROJECT



DATA CLEANING



```
print("Jumlah ID unik:", df['participant_id'].nunique())
print("Jumlah baris:", len(df))

print("Jumlah duplikasi baris:", df.duplicated().sum())
print("Jumlah duplikasi participant_id:", df['participant_id'].duplicated().sum())
```

Show hidden output

```
missing = pd.DataFrame({
    'Missing': df.isnull().sum(),
    'Persentase (%)': (df.isnull().mean() * 100).round(2)
})
```

```
missing = missing.sort_values('Missing', ascending=False)
```

```
missing
```

```
TARGET = "ckd_present"
```

```
DROP_FEATURES = [
    "participant_id",
    "ckd_stage",
    "egfr"
]
```

```
X = df.drop(columns=[TARGET] + DROP_FEATURES, errors="ignore")
y = df[TARGET]
```


Proses untuk memastikan data yang digunakan sudah bersih, konsisten, dan siap untuk tahap analisis dan pemodelan.

- Cek Missing Value — Mengecek nilai kosong pada setiap variabel
- Cek Duplikasi — Memastikan tidak ada data yang tercatat lebih dari satu kali
- Cek Target — Memisahkan variabel target CKD/Non-CKD dari fitur yang digunakan untuk prediksi
- Seleksi Fitur — Menghapus fitur yang tidak digunakan untuk menghindari data leakage pada proses pemodelan

Exploratory Data Analysis (EDA)

Insight


Data CKD lebih banyak dibandingkan Not CKD, sehingga distribusi kedua kelas belum sepenuhnya seimbang.



Exploratory Data Analysis (EDA)

Insight

Kelompok CKD memiliki serum creatinine yang cenderung lebih tinggi dan variasinya lebih besar dibandingkan Non-CKD.



PREPROCESSING DATA



```
numeric_transformer = Pipeline([
    ("imputer", SimpleImputer(strategy="median")),
    ("scaler", StandardScaler())
])

categorical_transformer = Pipeline([
    ("imputer", SimpleImputer(strategy="most_frequent")),
    ("onehot", OneHotEncoder(
        handle_unknown="ignore"
    ))
])
```

```
preprocessor = ColumnTransformer([
    ("num", numeric_transformer, numeric_features),
    ("cat", categorical_transformer, categorical_features)
])
```

```
X_train, X_test, y_train, y_test = train_test_split(
    X,
    y,
    test_size=0.20,
    stratify=y,
    random_state=RANDOM_STATE
)
```

Sebelum model dijalankan, data dipersiapkan terlebih dahulu agar dapat digunakan dalam proses klasifikasi.

- Missing value → numerik menggunakan median, kategorikal menggunakan nilai yang paling sering muncul
- Encoding → variabel kategorikal diubah menggunakan One-Hot Encoding
- Scaling → variabel numerik menggunakan StandardScaler
- Train-Test Split → 80% data training dan 20% data testing

MODEL MACHINE LEARNING YANG DIGUNAKAN



```
models = {  
    "Logistic Regression": LogisticRegression(  
        max_iter=2000,  
        random_state=RANDOM_STATE  
    ),  
    "Random Forest": RandomForestClassifier(  
        n_estimators=200,  
        random_state=RANDOM_STATE,  
        n_jobs=-1  
    ),  
    "XGBoost": XGBClassifier(  
        n_estimators=200,  
        random_state=RANDOM_STATE,  
        eval_metric="logloss"  
    ),  
    "LightGBM": LGBMClassifier(  
        n_estimators=200,  
        random_state=RANDOM_STATE,  
        verbosity=-1  
    )  
}
```

Pada project ini digunakan empat metode untuk membandingkan kemampuan model dalam mengklasifikasikan kondisi CKD dan Non-CKD.

1. Logistic Regression

Digunakan sebagai model dasar untuk klasifikasi dua kelas

2. Random Forest

Menggunakan banyak decision tree untuk menghasilkan prediksi

3. XGBoost

Menggunakan teknik boosting untuk meningkatkan hasil prediksi

4. LightGBM

Model boosting yang dirancang untuk proses pembelajaran yang lebih efisien

CROSS-VALIDATION



Menggunakan 5-fold cross-validation untuk melihat konsistensi performa model

	Model	Accuracy	Precision	Recall/Sensitivity	F1	ROC-AUC
3	LightGBM	0.992353	0.995796	0.993256	0.994523	0.999740
2	XGBoost	0.990258	0.994145	0.991908	0.993024	0.999573
1	Random Forest	0.970878	0.982808	0.975423	0.979096	0.996559
0	Logistic Regression	0.866854	0.870924	0.950396	0.908922	0.900811

Setelah model dibandingkan, model dengan performa awal yang lebih baik dilanjutkan ke tahap tuning.
Tujuannya untuk mendapatkan performa model yang lebih optimal.

HYPERPARAMETER TUNING



Dilakukan pada 3 model dengan hasil terbaik untuk mencari pengaturan model yang lebih sesuai

	Model	Best ROC-AUC	Best Parameters
0	LightGBM	0.999768	<code>{'model__subsample': 1.0, 'model__num_leaves':...</code>
1	XGBoost	0.999643	<code>{'model__subsample': 0.8, 'model__n_estimators...</code>
2	Random Forest	0.996507	<code>{'model__n_estimators': 500, 'model__min_sampl...</code>

Model dengan hasil terbaik setelah tuning digunakan sebagai final model untuk melakukan prediksi pada data testing.


FINAL MODEL



	Metric	Score
0	Accuracy	0.993716
1	Precision	0.996993
2	Sensitivity/Recall	0.994005
3	Specificity	0.993046
4	F1-Score	0.995497
5	ROC-AUC	0.999842


Berdasarkan hasil pengujian, **LightGBM** dipilih sebagai model akhir karena mampu memberikan hasil klasifikasi CKD dan Non-CKD dengan performa yang sangat baik.

CONFUSION MATRIX




Confusion matrix menunjukkan bahwa model LightGBM dapat membedakan data CKD dan Non-CKD dengan baik. Sebagian besar data berhasil diklasifikasikan sesuai kondisi sebenarnya.

FEATURE IMPORTANCE



Hasil feature importance menunjukkan bahwa serum, age, dan albumin menjadi fitur yang paling berpengaruh terhadap model.

SHAP



Berdasarkan SHAP, serum creatinine, albumin-creatinine ratio, dan age menjadi fitur yang paling banyak memengaruhi hasil prediksi model.

IMPLEMENTASI WEB PREDIKSI CKD

CKD Predictor

Prediksi Penyakit Ginjal Kronis Berdasarkan Indikator Kesehatan

[Home](#)[Prediksi](#)[Tentang](#)

UNTUK EDUKASI & PENELITIAN

Prediksi Penyakit Ginjal Kronis

Prediksi CKD / Non-CKD Berdasarkan Indikator Kesehatan

Aplikasi berbasis machine learning yang membantu memperkirakan kemungkinan Penyakit Ginjal Kronis (CKD) berdasarkan 25 indikator kesehatan klinis dan laboratorium untuk tujuan edukasi dan penelitian akademis.

[Mulai Prediksi →](#)

Informasi Model

METODE

Supervised Binary Classification

MODEL FINAL

Tuned LightGBM

DATASET

CKD-NHANES 2021-2023

INPUT FITUR

25 Indikator Kesehatan

RISIKO DAN LIMITATION AI

1. Keterbatasan Data

Risiko: Missing value dan data CKD–Non-CKD tidak seimbang

Upaya: Preprocessing dan evaluasi dengan beberapa metrik

2. Generalisasi Model

Risiko: Hasil model pada dataset ini belum tentu sama pada data baru

Upaya: Uji model pada dataset atau populasi lain

3. Kesalahan Prediksi

Risiko: Model masih dapat menghasilkan kesalahan klasifikasi, terutama false negative

Upaya: Memperhatikan Recall, F1-Score, ROC-AUC, dan confusion matrix

4. Penggunaan pada Pasien

Risiko: Hasil prediksi dapat disalahartikan sebagai diagnosis

Upaya: Model digunakan sebagai alat bantu, bukan pengganti keputusan tenaga kesehatan



KESIMPULAN

Proyek ini berhasil mengembangkan model Machine Learning untuk memprediksi Penyakit Ginjal Kronis (CKD) dan Non-CKD berdasarkan indikator kesehatan. Dengan membandingkan Logistic Regression, Random Forest, XGBoost, dan LightGBM, proses preprocessing, cross-validation, hingga hyperparameter tuning menghasilkan **LightGBM** sebagai model terbaik dengan **Accuracy 99,37% dan ROC-AUC 99,98%**.

Pada tahap implementasi, model terbaik diterapkan ke dalam web CKD Predictor yang memungkinkan pengguna melakukan prediksi berdasarkan indikator kesehatan. Hasil ini menunjukkan bahwa Machine Learning dapat menjadi pendukung dalam proses prediksi awal CKD, namun model tetap perlu diuji pada data dan populasi yang lebih beragam sebelum dapat diterapkan pada kondisi klinis nyata.

THANK YOU

